

Reconocimiento de la Actividad Humana a partir de la Acelerometría de Muslo y Muñeca



Alejandro Castellanos Alonso¹, Juan C. Álvarez Álvarez², Antonio M. López Rodríguez³

Área de Conocimiento: Ingeniería y Arquitectura

Programa Oficial de Doctorado en Energía y Control de Procesos



Universidad de Oviedo

Departamento de Ingeniería Eléctrica, Electrónica, de Comunicaciones y de Sistemas

Directores: Juan Carlos Álvarez Álvarez, Antonio Miguel López Rodríguez

Tutor Académico: José María Enguita González

Contacto: ¹castellanosalejandro@uniovi.es, ²juan@uniovi.es, ³amlopez@uniovi.es



1. Introducción

En 2020 el Instituto de Salud Carlos III (ISCIII) de España estableció la Infraestructura de Medicina de Precisión Asociada a Ciencia y Tecnología (IMPACT), la cual abordará la creación de una cohorte de base poblacional compuesta por aproximadamente 200.000 individuos. Su objetivo será permitir la integración de datos de estilo de vida, información clínica e información genética para la posterior generación de modelos predictivos que faciliten la implantación efectiva de la Medicina de Precisión. La **cohorte IMPACT** incluye evaluaciones de la actividad física, el comportamiento sedentario y la forma física de los individuos participantes [1]. Durante 7 días consecutivos, se registrarán **parámetros biomecánicos** y **fisiológicos** mediante dos **monitores portátiles** que integran un **acelerómetro triaxial** y un **giroscopio** colocados tanto en la muñeca como en el muslo de los participantes.

Este estudio pretende arrojar luz sobre la viabilidad de la identificación de la actividad física a partir de la **acelerometría en el muslo y la muñeca**, al tiempo que analiza la eficacia de la colocación simultánea de los dos dispositivos de monitorización. Se han utilizado **conjuntos de datos públicos**, cubriendo una variedad de actividades. Posteriormente, se han aplicado estructuras basadas en una **Red Neuronal Convolucional Profunda (CNN)** para la clasificación.

3. Resultados

Tras completar el proceso de búsqueda, se analizaron las 10 mejores combinaciones de **hiperparámetros**. En todos los casos existe una puntuación similar ($m \pm s = 0,93250 \pm 0,00066$), por lo que se han seleccionado aquellos hiperparámetros que simplifican la arquitectura del modelo; **minimizando el número de capas ocultas, el número de filtros convolucionales y su tamaño**.

Tabla 2.- Hiperparámetros óptimos* del modelo de clasificación.

Nº. de Capas	Optimizador	Función de activación	Tamaño del mini-lote	Número de filtros	Tamaño del Filtro	Tasa de Aprendizaje
2	RMS Prop	ReLU	10	12	7	0.0004549

* Tiempo de cómputo para optimizar los hiperparámetros del modelo mediante *Random Search* [5]: 1 día, 12 horas, 14 minutos y 07 segundos.


Tabla 3.- Precisión (tanto por uno) de las Redes Neuronales Convolucionales.

Accuracy	Train Data*	Validation Data	Test Data
NET_TW	0.8734	0.8685	0.8524
NET_T	0.7189	0.7141	0.6868
NET_W	0.7319	0.7316	0.6788

* Early Stopping implementado en el entrenamiento. *Patience* = 5 épocas.

Las CNNs óptimas poseen **7574 parámetros entrenables**.

2. Método



2.1.- Datasets

Se han considerado los *datasets* analizados en [2], seleccionando **RSD: Realistic Sensor Displacement Dataset** [3] y **DSAD: Daily and Sport Activities Dataset** [4].

2.2.- Preprocesado de Datos


- ☐ Alineación con ejes anatómicos.
- ☐ RSD: 51585 ventanas de datos.
- ☐ DSA: 45443 ventanas de datos.
- ☐ Salida de cada ventana: moda.

Tabla 1.- Segmentación de *datasets*.

Frecuencia de remuestreo	25 [Hz]
Ventanas de segmentación	2 [s]
Solapamiento de ventanas	1 [s]

2.3.- CNNs

- ☐ “NET_TW”: aceleraciones ($\vec{a}$) + velocidades rotacionales ($\vec{\omega}$) en muslo y muñeca.
- ☐ “NET_T”: $\vec{a} + \vec{\omega}$ en muslo.
- ☐ “NET_W”: $\vec{a} + \vec{\omega}$ en muñeca.
- ☐ Espacio de búsqueda (Ω) de hiperparámetros óptimos.



4. Conclusiones y Discusión

- ✓ Clasificación basada en los datos de **una sola extremidad** → precisión comparable ($\sim 68-69$ [%]).
- ✓ La precisión se incrementa un 15 [%] al **combinar datos de muslo y muñeca**.
- ✓ Actividades no atómicas: se clasifican en diversas clases objetivo (Tabla 5).
- ✓ Confusión durante las transiciones entre actividades.

Tabla 4.- Extracto de la matriz de confusión (NET_TW, datos de test) para la clase objetivo "Walking" (columna).

	Walking
No Activity	283
Walking	1607
Walking (treadmill-flat)	429
Walking (treadmill-inclined)	49
Knees (alternating) to the breast	10
Going down (stairs)	118
Moving around in an elevator	49
Basketball	19

Trabajo Futuro

Clustering
Establecimiento de "Superclases"

Tabla 5.- Ídem que la Tabla 4 para la clase "Baloncesto" (fila).

	No Activity	Walking	Walking (treadmill-flat)	Walking (treadmill-inclined)	Running	Going up (stairs)	Going down (stairs)	Moving around in an elevator	Exercising on a stepper	Exercising on a cross trainer	Jumping	Basketball
Basketball	189	19	9	11	31	22	23	65	31	30	36	978

Referencias

- [1] David Martínez Gómez, "Valoraciones de la actividad física y condición física en la cohorte nacional IMPACT" in *VIII Simposio ETERNET: Ejercicio Físico para la salud a lo largo de la vida*, A. Soriano Maldonado, Rodríguez Pérez M. A., B. Martínez Téllez, and E. García Artero, Eds., Almería: Editorial Universidad de Almería, Oct. 2023.
- [2] F. Demrozi, G. Pravadelli, A. Bihorac, and P. Rashidi, "Human Activity Recognition Using Inertial, Physiological and Environmental Sensors: A Comprehensive Survey," *IEEE Access*, vol. 8, Institute of Electrical and Electronics Engineers Inc., pp. 210816–210836, 2020. doi: 10.1109/ACCESS.2020.3037715.
- [3] O. Baños, M. Damas, H. Pomares, I. Rojas, M. A. Tóth, and O. Amft, "A benchmark dataset to evaluate sensor displacement in activity recognition," in *UbiComp'12 - Proceedings of the 2012 ACM Conference on Ubiquitous Computing*, Association for Computing Machinery, 2012, pp. 1026–1035. doi: 10.1145/2370216.2370437.
- [4] K. Altun, B. Barshan, and O. Tuncel, "Comparative study on classifying human activities with miniature inertial and magnetic sensors," *Pattern Recognition*, vol. 43, no. 10, pp. 3605–3620, Oct. 2010. doi: 10.1016/j.patcog.2010.04.019.
- [5] J. Bergstra, J. B. Ca, and Y. B. Ca, "Random Search for Hyper-Parameter Optimization Yoshua Bengio," 2012. [Online]. Available: <http://scikit-learn.sourceforge.net>.

Agradecimientos

Este estudio ha sido financiado por el Instituto de Salud Carlos III a través del proyecto "PMP22/00028" (Fondos EU Next Generation, Mecanismo de Recuperación y Resiliencia).

