

Data Visualization for Semi-Supervised Learning on the WearablePerMed Physical Activity Dataset

Pablo Laviana Martínez, Antonio Miguel López Rodríguez, Ignacio Díaz Blanco

Abstract— En este estudio se presenta una técnica de aprendizaje Semi-Supervisado basada en Morphing Projections y Linked Selections, diseñada para facilitar el proceso de etiquetado de datos en el contexto de la monitorización de la actividad física. Esta metodología combina visualización interactiva, técnicas de reducción de dimensionalidad y selección de datos, permitiendo a los usuarios explorar secuencias complejas de manera intuitiva, eficiente y explicable. La técnica fue aplicada a un individuo seleccionado al azar del conjunto de datos WearablePerMed, el cual incluye registros obtenidos mediante acelerómetros ubicados en la muñeca y el muslo. El sujeto fue monitorizado de forma continua durante siete días en un entorno de vida cotidiana, proporcionando un contexto realista y no controlado para la validación del enfoque propuesto. Como resultado, se alcanzó una tasa de etiquetado correcto y explicable del 95%, lo que representa un avance significativo en la automatización del etiquetado de datos y una reducción sustancial en la necesidad de anotaciones manuales extensas.

Index Terms— Aprendizaje Semi-Supervisado, Acelerómetros, Actividad física, Morphing Projections, PCA, t-SNE, UMAP, autoencoders

I. INTRODUCCIÓN

LA monitorización de la actividad física mediante acelerómetros desempeña un papel clave en estudios sobre salud, comportamiento humano y medicina preventiva. Estos sensores permiten recopilar grandes volúmenes de datos en entornos no controlados, lo que plantea desafíos en su procesamiento e interpretación. Uno de los principales retos es el etiquetado de actividades, fundamental para entrenar modelos de aprendizaje automático, pero que sigue siendo costoso y propenso a errores, especialmente cuando se trabaja con datos recogidos en contextos de vida cotidiana, donde la variabilidad del comportamiento es elevada.

Este estudio ha sido financiado mediante las becas de colaboración para el fomento de las vocaciones científicas para estudiantes de Máster del Principado de Asturias.

Pablo Laviana Martínez, está trabajando en colaboración con el grupo de investigación SiMuR perteneciente a la Universidad de Oviedo, España. (pablolaviana10@gmail.com).

Antonio Miguel López Rodríguez, profesor titular de la Universidad de Oviedo perteneciente al grupo de investigación SiMur. (amlopez@uniovi.es)

Ignacio Díaz Blanco, profesor titular de la Universidad de Oviedo perteneciente al grupo de investigación GSDPI. (idiiaz@uniovi.es)

Las técnicas de visualización de datos procedentes de acelerómetros, basadas en métodos de reducción de dimensionalidad, son ampliamente utilizadas para explorar y analizar patrones de movimiento. Entre ellas, el Análisis de Componentes Principales (PCA) se ha consolidado como una solución lineal y robusta, tal como se demuestra en [1]. No obstante, la simplicidad de PCA ha impulsado el desarrollo y la adopción de algoritmos de reducción no lineal, como t-SNE [2] y UMAP [3], que permiten preservar de manera más efectiva las relaciones locales en espacios de alta dimensionalidad. En [4] se ha demostrado que estas técnicas son especialmente útiles en contextos donde los datos presentan estructuras complejas o no lineales, como es común en registros de actividad física obtenidos en entornos reales.

Diversos estudios basados en datos de acelerómetros han obtenido resultados significativos tanto en tareas de clasificación [5] como de regresión [6] (con el objetivo de estimar el nivel de intensidad física mediante el equivalente metabólico (MET)). Ambos enfoques se fundamentan en la extracción de características a partir de ventanas de señales temporales, lo que ha consolidado un conjunto de descriptores estándar ampliamente utilizados en la literatura. Estas características permiten capturar patrones relevantes del movimiento, facilitando la modelización de la actividad física en diferentes contextos y niveles de intensidad.

Otros enfoques para establecer una métrica de comparación entre distintos tipos de actividad física se basan en la segmentación de las series temporales mediante ventanas y en el uso del algoritmo Dynamic Time Warping (DTW) [7]. Esta técnica ha demostrado ser altamente eficaz para alinear y comparar secuencias temporales, especialmente cuando las actividades presentan variaciones de fase debido al recorte por ventanas. Sin embargo, su alto coste computacional y limitada escalabilidad la convierten en una opción poco adecuada para conjuntos de datos extensos o aplicaciones en tiempo real.

[8] destaca la importancia de la visualización de datos y de la interacción del usuario en el proceso analítico, subrayando que la participación activa del ser humano en la exploración de la información es clave para mejorar la comprensión y generar conocimiento. Este enfoque centrado en el usuario no solo facilita una validación más intuitiva de los resultados, sino que también favorece el descubrimiento de patrones complejos que

podrían pasar desapercibidos mediante técnicas puramente automatizadas. A partir de esta perspectiva surgen enfoques como dual-iDR [9], que permite obtener conclusiones a través de una visión dual del problema, o Morphing Projections [10], que facilita la combinación interactiva de diferentes vistas del conjunto de datos para profundizar en el análisis.




Fig. 1. Esquema Visualización Interactiva

Como se discute en [11], los principales enfoques de aprendizaje semi-supervisado se fundamentan en entrenar un modelo de aprendizaje automático utilizando únicamente los datos etiquetados, y posteriormente emplear dicho modelo para inferir etiquetas sobre los datos no etiquetados. Esta inferencia se aplica a los ejemplos que el modelo clasifica con alta confianza, lo que permite ampliar progresivamente el conjunto de datos etiquetados sin necesidad de intervención humana directa. Si bien estos métodos han demostrado un rendimiento notable en entornos controlados (donde las clases son bien definidas y representativas), su escalabilidad y eficacia en contextos abiertos o no estructurados aún no ha sido plenamente validada, especialmente en escenarios de actividad física con alta variabilidad e incertidumbre.

Los principales problemas identificados en los enfoques actuales son, por un lado, la baja escalabilidad en conjuntos de datos de gran tamaño cuando se emplea Dynamic Time Warping (DTW) como métrica de comparación, y por otro, la dependencia excesiva de la representatividad del subconjunto de datos etiquetados, lo que limita la generalización del modelo en escenarios complejos o no previamente observados.

Por ello, en este trabajo se propone un enfoque basado en visualización interactiva, que combina múltiples vistas generadas mediante Morphing Projections con la representación directa de las señales temporales a través de la técnica de Linked Selections. Esta integración permite al usuario explorar y relacionar dinámicamente diferentes perspectivas de los datos, facilitando la identificación de patrones coherentes y mejorando el proceso de etiquetado en contextos donde los métodos automáticos tradicionales resultan limitados.

II. MATERIALES Y MÉTODOS

A. Paper Collection

Para la elaboración del estado del arte de este artículo, se seleccionaron las bases de datos IEEE Xplore, Web of Science, Scopus y Google Scholar como fuentes de referencia. La elección de estas plataformas responde al objetivo de abarcar tanto el enfoque científico como el tecnológico del tema,

garantizando así una revisión amplia, actualizada y relevante para los propósitos del estudio.

Las palabras claves referentes a la búsqueda estaban relacionadas con accelerometers, semi-supervised learning, IMU, raw acceleration, classification of physical activities, data visualization. Por lo que las queries utilizadas contienen el siguiente grupo de palabras: (accelerometer OR IMU) AND physical activities, t-SNE and accelerometer, Semi-Supervised learning and accelerometer, raw and accelerometer classification.

El criterio de inclusion para los papers es el siguiente:

- Los estudios están publicados en inglés.
- Los estudios están publicados en los últimos 20 años.
- Los participantes de los estudios emplean a personas sanas.

El primer criterio de exclusion es el siguiente:

- Los estudios no provienen de Conference Proceedings con alto número de citas.
- Los estudios no están publicados en un Journal o en una Book Series.

El segundo criterio de exclusion es el siguiente:

- Los estudios no presentan resultados cuantitativos.
- Los estudios no presentan resultados cualitativos.

El tercer criterio de exclusion es el siguiente:

- No se incluye una discusión sobre las limitaciones del modelo.
- Los estudios que involucran a personas no tienen un tamaño de muestra adecuado.
- No se ha realizado un procedimiento riguroso en los experimentos.




Fig. 2. Metodología PRISMA

B. Paper Collection

En este estudio, se establecen las siguientes variables clave tomando como referencia acrónimos ampliamente utilizados en la literatura científica: número de muestras (n), red neuronal (NN), T-distributed Stochastic Neighbor Embedding (t-SNE), Uniform Manifold Approximation and Projection (UMAP), Euclidean Norm Minus One (ENMO) y error cuadrático medio (RMSE).

C. Related Works

El análisis de los diversos trabajos permitió distinguir tres enfoques bien definidos:

- Estudios basados en técnicas de reducción de la dimensionalidad y aprendizaje no supervisado.
- Estudios basados en la Dynamic Time Warping.
- Estudios basados en la extracción de características para tareas de clasificación y de regression.
- Estudios basados en el entrenamiento de un modelo y label propagation.

Se ha detectado que los estudios que aplican técnicas de reducción de dimensionalidad suelen recurrir a los mismos algoritmos, obteniendo resultados satisfactorios.

El algoritmo Principal Component Analysis (PCA) ha sido utilizado en [1] obteniendo buenos resultados en la separación de actividades. Este enfoque se basa en transformar las variables originales en un nuevo conjunto de variables no correlacionadas, conocidas como componentes principales, que conservan la mayor parte de la varianza presente en los datos. Es importante señalar que esta transformación es lineal, por lo que no permite capturar relaciones no lineales entre las variables.

En [4] se demuestra que la utilización de técnicas no lineales de reducción de la dimensionalidad, como t-SNE y UMAP, mejora notablemente la identificación de grupos de actividades. A diferencia de métodos lineales como PCA, estas técnicas conservan la estructura local de los datos al proyectarlos en espacios de menor dimensión, lo que facilita una representación visual más fiel de patrones complejos y relaciones no lineales.

Dynamic Time Warping (DTW) ha demostrado ser eficaz en la comparación de señales temporales de actividad, gracias a su capacidad para comparar secuencias similares aunque desfasadas en el tiempo. Esta propiedad la hace especialmente útil en tareas de reconocimiento de patrones y clasificación de actividades. Generalmente, estas comparaciones se realizan a partir de particiones regulares de las señales originales, consiguiendo ventanas de longitud fija. En [7] se presenta un caso de estudio en el que la aplicación de esta técnica ha facilitado la obtención de patrones claramente diferenciados para cada actividad. Sin embargo, el coste computacional de esta técnica es muy elevado siendo su uso en grandes conjuntos de datos totalmente ineficiente.

Adicionalmente, se han considerado artículos enfocados en la clasificación del tipo de actividad y en la regresión para identificar el nivel de intensidad de la actividad física. El principal motivo de esta elección es que, en estos estudios, se han extraído los descriptores más utilizados y relevantes para el análisis de series temporales multimodales. Ejemplos de éxito y relevancia son [5] en tareas de clasificación y [6] en tareas de regresión. A partir de estos estudios se han extraído las principales características:

- Media, desviación típica, mínimo, máximo, percentil 25%, percentil 75% de cada componente x, y, z de aceleración por ventana.
- Correlación de las señales x-y, x-z, y-z de las componentes de aceleración por ventana.
- Media, potencia y frecuencia del primer armónico, potencia y frecuencia del segundo armónico, entropía espectral, número de picos y prominencia media de la señal de ENMO por ventana.

Por último, los enfoques de aprendizaje semi-supervisado se basan en conjuntos de datos que incluyen tanto muestras etiquetadas como no etiquetadas. Inicialmente, se entrena un modelo de machine learning utilizando únicamente los datos etiquetados, con el objetivo de lograr un buen rendimiento en la clasificación del tipo de actividad. Posteriormente, el modelo se aplica a los datos no etiquetados, y aquellas predicciones que superan un umbral de confianza predefinido se consideran suficientemente fiables como para ser tratadas como etiquetas válidas. Con estas nuevas muestras etiquetadas, el modelo se reentrena, y este proceso se repite de forma iterativa. Si bien en [11] se demuestra que esta estrategia puede ofrecer resultados prometedores, su eficacia depende en gran medida de que las actividades inicialmente etiquetadas sean representativas del conjunto total. Esta condición puede no cumplirse en escenarios reales donde no se ejerce un control estricto sobre el comportamiento del usuario.

D. Métodos

El estudio WearablePerMed tiene como meta principal descubrir patrones en la actividad física de las personas participantes, prestando especial atención a dos aspectos fundamentales: qué tipo de actividad están realizando y cuánta intensidad implica esa actividad en cada momento.

Participantes

El conjunto de datos, llamado WearablePerMed, fue cuidadosamente diseñado para incluir 120 personas con una media de edad de 35 años (± 10), garantizando una distribución equilibrada tanto por sexo como por edad. Se seleccionaron 15 hombres y 15 mujeres en cada uno de estos grupos de edad: 17 a 29 años, 30 a 49, 50 a 64, y 65 a 79 años. Esta forma de selección busca evitar sesgos y asegurar que los resultados puedan aplicarse a una población más amplia.

Protocolo

La recolección de datos se organizó en tres etapas claramente diferenciadas, que combinan tanto condiciones controladas como observaciones en entornos naturales.

• Primera fase

En la primera parte, cada persona permaneció acostada durante media hora mientras se registraban distintos parámetros usando una mascarilla metabólica (Cosmed K5), sensores en muñeca, cadera y muslo, y una banda en el pecho para medir la frecuencia cardíaca.

Después, se pidió a los participantes que completaran una serie de actividades mientras eran grabados por una cámara HD y continuaban usando los mismos dispositivos. Las actividades incluyeron:

- Caminar en una cinta durante 4 minutos a velocidades que aumentaban desde 2 hasta 8 km/h.
- Una prueba de levantarse y sentarse durante 30 segundos sobre una plataforma de fuerza.
- Ejercicio en bicicleta estática con incrementos de esfuerzo progresivos hasta alcanzar el cansancio en unos 8 a 12 minutos, mientras se monitorizaba la respiración y el ritmo cardíaco.

• Segunda fase

Durante los siete días siguientes, las personas llevaron los sensores (en muñeca, muslo y cadera) junto con una cámara corporal. Durante este tiempo realizaron sus actividades cotidianas con normalidad, lo que permitió capturar datos en un entorno realista.

• Tercera fase

Al finalizar la semana, los participantes realizaron una lista de 14 actividades durante dos minutos cada una, que incluían desde tareas sedentarias como ver televisión o leer, hasta otras más dinámicas como caminar con bolsas, subir escaleras o correr. También se incluyeron actividades funcionales como barrer o mover objetos, y situaciones de trabajo tanto sentado como de pie.

Instrumentación

Los sensores Matrix, colocados en el muslo, la cadera y la muñeca, están equipados con tecnología avanzada capaz de registrar el movimiento corporal, así como parámetros fisiológicos y ambientales. Cada dispositivo cuenta con un acelerómetro y un giroscopio triaxiales que permiten medir con alta precisión tanto la aceleración como la velocidad angular del cuerpo. Además, incorporan un sensor PPG para la monitorización continua de la frecuencia cardíaca, junto con sensores de temperatura corporal y ambiente, lo que permite interpretar los datos recogidos en función de las condiciones del entorno.

Adicionalmente, los participantes llevan una cámara corporal portátil que captura imágenes de forma continua para documentar visualmente las actividades que realizan.

Los acelerómetros recopilan datos a una frecuencia de 25 Hz y almacenan cada medición con una marca temporal en formato Unix. Sin embargo, al operar de forma autónoma, cada dispositivo utiliza su propio reloj interno, lo que ha provocado ligeras discrepancias temporales entre sensores. Para corregir esta desalineación, fue necesario aplicar un procedimiento de ajuste temporal que permitiera sincronizar correctamente las señales y asegurar una comparación precisa entre ellas.

Extracción de características

Considerando el alto volumen de datos generado por los acelerómetros, se ha seleccionado un tamaño de ventana de 30 segundos para el análisis de las series temporales y la extracción de descriptores. Esta decisión, respaldada por un término medio entre [5] y [6], busca capturar de forma representativa la actividad física, al tiempo que permite reducir adecuadamente la información recopilada.

Las características extraídas de las series temporales se han definido a partir de descriptores ampliamente reconocidos y validados en la literatura:

- Media, desviación típica, mínimo, máximo, percentil 25%, percentil 75% de cada componente x, y, z de aceleración por ventana.
- Correlación de las señales x-y, x-z, y-z de las componentes de aceleración por ventana.
- Media, potencia y frecuencia del primer armónico, potencia y frecuencia del segundo armónico, entropía espectral, número de picos y prominencia media de la señal de ENMO por ventana.

No obstante, dado el elevado número de dimensiones resultante de los vectores generados con estos descriptores, se optó por seleccionar únicamente un subconjunto representativo de ellos. Dicho subconjunto se basa en:

- Media de cada componente x, y, z de aceleración por Ventana tanto para el acelerómetro de la muñeca como para el del muslo.

$$\mu = \frac{1}{N} \cdot \sum_{j=1}^N v_j \quad (1)$$

- Media de la señal de ENMO por ventana.

$$ENMO = \max\left(0, \sqrt{(a_x)^2 + (a_y)^2 + (a_z)^2} - 1\right) \quad (2)$$

Preprocesado de la matriz de características

Al trabajar con datos de aceleración reales, puede ocurrir que algunas mediciones presenten valores atípicos, los cuales pueden distorsionar las características y hacer que se desvíen considerablemente del resto de los datos. Para abordar este problema, se ha implementado un filtro que utiliza tanto los percentiles como el rango intercuartílico. Según este método,

cualquier dato que se encuentre fuera del rango de (3) será descartado, asegurando así que las características sean más consistentes y representativas.

$$feature_i \in [Q1_i - 1.5 \cdot IQR_i, Q3_i + 1.5 \cdot IQR_i] \quad (3)$$

Con el fin de evitar que algunas características tengan mayor peso que otras debido a diferencias en sus escalas, se aplica un proceso de normalización.

$$z = \frac{x - \mu}{\sigma} \quad (4)$$

Visualización

Se realiza un agrupamiento jerárquico utilizando el método de Ward sobre la matriz de datos previamente normalizados. Este procedimiento permite identificar patrones de similitud entre las observaciones y agruparlas en un conjunto de MetaClusters. Estos MetaClusters servirán como base para facilitar la exploración y visualización de los datos en la herramienta interactiva, permitiendo al usuario interpretar de manera más clara las relaciones en el conjunto de datos.

Con el fin de explorar la estructura interna de los datos y facilitar su visualización, se aplican técnicas de reducción de dimensionalidad que permiten proyectar el conjunto de datos en dos dimensiones. Cada algoritmo proporciona una perspectiva complementaria sobre las relaciones entre las observaciones, lo que en conjunto enriquece el análisis interactivo mediante Morphing Projections.

$$\alpha_i = \frac{e^{\lambda_i}}{\sum_{j=0}^N e^{\lambda_j}} \quad (5)$$

$$pr = \sum_{i=0}^N \alpha_i \cdot pr_i \quad (6)$$

Donde las proyecciones (pr_i) que se utilizan son:

PCA: este algoritmo lineal permite obtener una visión global simplificada de los datos, conservando la mayor parte de la varianza. Es útil para detectar la orientación principal de los datos, identificar separaciones lineales entre grupos y observar tendencias generales.

t-SNE: este algoritmo no lineal se enfoca en identificar clústeres densos preservando la estructura local de los datos. Sin embargo, no conserva las distancias absolutas ni las relaciones entre clusters. Se emplea la aproximación “barnes hut” con una perplexity=500 y 1000 iteraciones.

UMAP: la literatura defiende que es similar en cuanto a la preservación de relaciones locales que t-SNE pero con la ventaja adicional de mantener mejor coherencia global, aunque no se ha demostrado para todos los casos. Se emplean 30 vecinos con mínima distancia=0.3 y se ha utilizado la métrica euclídea como medida de similitud.

Autoencoders: emplean redes neuronales para aprender una representación comprimida de los datos. A través de este proceso, se crea un espacio latente en el que se proyectan los datos originales, lo que permite descubrir relaciones complejas que otras técnicas podrían no captar. Por ello, se emplea una arquitectura




Fig. 3. Arquitectura Autoencoder

Que se entrena con el optimizador adam y función a minimizar el error cuadrático medio. Se entrena durante 200 épocas con batch size de 1024 y se aplica early stopping de delta de 0.001 con un paciente de 10 en validación. Para el entrenamiento se emplea un 60 % de train, 20% de validación y 20% de test para corroborar su buen desempeño. Todas las capas presentan regularización L1=0.01 y dropout de 0.2. Finalmente, todos los datos se proyectan en el espacio latente 2D.

Para expresar la evolución temporal de la intensidad física que realiza el participante durante los 7 días, se grafica el máximo de cada ventana de la señal de ENMO tanto para la muñeca como para el muslo. Dichos gráficos están enlazados con las distintas vistas del Morphing Projections favoreciendo la conexión temporal y espacial.

Se crean unos encodings para los MetaClusters y los datos etiquetadas que también están interconectados con el Morphing Projections y la visión temporal. Dichos encodings se han empleado con un jitter de radio de 0.05 y un jitter de ángulo de 0.1.

$$\theta_{jitter} = \theta + rand(-jitter_{\text{ángulo}}, jitter_{\text{ángulo}}) \quad (7)$$

$$r_{jitter} = 1 + rand(-jitter_{\text{radio}}, jitter_{\text{radio}}) \quad (8)$$

$$x = A \cdot (r_{jitter} \cdot \cos(\theta_{jitter})) + t_x \quad (9)$$

$$y = A \cdot (r_{jitter} \cdot \sin(\theta_{jitter})) + t_y \quad (10)$$

Por último, se añade una caja interactiva que, en caso de selección de puntos, permite mostrar temporalmente los 5 primeros puntos seleccionados. Funcionalidad que facilita la inspección detallada de los datos que permite explorar de manera más eficiente los eventos o intervalos de interés en la señal. Dichos puntos pueden ser analizados empleando las fotos obtenidas por la cámara corporal portátil.

Métricas de evaluación

La primera métrica objetiva es el porcentaje de éxito en el etiquetado de todo el conjunto de datos, que mide la proporción de instancias correctamente etiquetadas respecto al total de datos disponibles.

La segunda métrica, es el tiempo necesario para el despliegue de la visión interactiva al cambiar de persona, comenzando desde las señales crudas de aceleración. Esta métrica mide la capacidad de eficiencia en la transición entre diferentes participantes sin pérdida de tiempo significativo. Es muy importante debido a la alta cantidad de datos por participante.

III. RESULTADOS

Los siguientes resultados se han obtenido a partir de una persona seleccionada de forma completamente aleatoria para el dataset WearablePerMed.

Las siguientes imágenes son coloreadas con los 7 clusters obtenidos por el cluterling aglomerativo.




Fig. 4. Proyección PCA




Fig. 5. Proyección UMAP




Fig. 6. Proyección t-SNE




Fig. 7. Proyección Autoencoder

A partir de las imágenes obtenidas por la cámara portatil, los MetaClusters pueden ser interpretados como las siguientes clases: 1 cluster asociado a estar de pie moviéndose, 4 clusters asociados a estar tumbado (debido a diferentes orientaciones), 1 cluster asociado a estar sentado con el brazo extendido y hacia abajo, y 1 cluster asociado a estar sentado moviendo el brazo. Obteniendo un porcentaje de etiquetado interpretable del 95%.

Fase	Tiempo
Extracción de características	4 minutos y 27 segundos
PCA	0.9 segundos
UMAP	47.5 segundos
t-SNE	7 minutos y 55 segundos
Autoencoder	24 segundos
Total	≈14 minutos

Tabla. 1. Tiempo de despliegue de la aplicación

IV. DISCUSIÓN

Los resultados obtenidos muestran el potencial de la visualización interactiva combinada con el Machine Learning para resolver problemas de aprendizaje Semi-Supervisado en series temporales multimodales en actividad física

Este esquema propuesto ha permitido etiquetar de forma consciente el 95 % del conjunto de datos por parte de una persona seleccionada al azar. A diferencia de los métodos de label propagation descritos en la literatura, esta propuesta no requiere una muestra representativa de puntos previamente etiquetados, ni el desarrollo de modelos de aprendizaje automático para lograr un etiquetado preciso. Sin embargo, en términos de velocidad, los enfoques basados en label propagation sí presentan una ventaja significativa, ya que, una vez entrenado el modelo, el proceso de etiquetado se resuelve enseguida.

Aunque los métodos que emplean Dynamic Time Warping como medida de similitud entre señales pueden ofrecer una descripción más precisa que la obtenida mediante vectores de características reducidas (como es el caso de este trabajo), su elevado coste computacional los vuelve completamente inviables para aplicaciones que implican grandes volúmenes de datos.

No obstante, es importante señalar que esta metodología propuesta también presenta ciertas limitaciones. Asumir que la actividad se mantiene constante dentro de cada ventana de 30 segundos puede no ser del todo preciso en algunos casos, ya que posibles transiciones o cambios de actividad dentro de ese intervalo quedarían completamente ignorados. Además, la inclusión del factor humano en el proceso de análisis implica costes adicionales, lo cual podría dificultar la aplicación de esta metodología en otros casos de estudio similares de etiquetado, especialmente cuando se dispone de recursos limitados.

Pese a estos inconvenientes, nuestro estudio proporciona un nuevo enfoque para el etiquetado de datos de actividad física que permite conectar el mundo del análisis y la visualización de datos con el conocimiento de los expertos en actividad física. El uso de visualizaciones interactivas y enlazadas mediante múltiples vistas facilita la identificación de patrones y la extracción de conclusiones que podrían pasar desapercibidas, contribuyendo así al avance en cuestiones relacionadas con la salud.

V. CONCLUSIÓN

En este estudio se ha demostrado la posibilidad de etiquetar un dataset de series temporales multimodales de actividad física de un participante durante 7 días en su vida cotidiana mediante visualización interactiva con múltiples vistas. Se propone como una nueva metodología muy atractiva que permite conectar a los analistas de datos con expertos en actividad física.

REFERENCES

- [1] T. Hasan, M. F. Bin Karim, M. K. Mahadi, M. M. Nishat, and F. Faisal, "Employment of Ensemble Machine Learning Methods for Human Activity Recognition," *J Healthc Eng*, vol. 2022, 2022, doi: 10.1155/2022/6963891.
- [2] L. Van Der Maaten and G. Hinton, "Visualizing Data using t-SNE," 2008.
- [3] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction," Feb. 2018, [Online]. Available: <http://arxiv.org/abs/1802.03426>
- [4] A. Jamieson, L. Murray, V. Stankovic, L. Stankovic, and A. Buis, "Unsupervised Cluster Analysis of Walking Activity Data for Healthy Individuals and Individuals with Lower Limb Amputation," *Sensors*, vol. 23, no. 19, Oct. 2023, doi: 10.3390/s23198164.
- [5] S. Chan *et al.*, "CAPTURE-24: A large dataset of wrist-worn activity tracker data collected in the wild for human activity recognition," Feb. 2024, [Online]. Available: <http://arxiv.org/abs/2402.19229>
- [6] J. Staudenmayer, D. Pober, S. Crouter, D. Bassett, and P. Freedson, "An artificial neural network to estimate physical activity energy expenditure and identify physical activity type from an accelerometer," *J Appl Physiol*, vol. 107, pp. 1300–1307, 2009, doi: 10.1152/jappphysiol.00465.2009.-The.
- [7] D. Džaja, M. Čibarić, G. Šeketa, and R. Magjarević, "Accelerometer-based algorithm for the segmentation and classification of repetitive human movements during workouts," *Automatika*, vol. 64, no. 2, pp. 211–224, 2023, doi: 10.1080/00051144.2022.2121247.
- [8] J. J. Van Wijk, "The Value of Visualization," 1998.
- [9] I. Díaz *et al.*, "Interactive dual projections for gene expression analysis," Bruges, Belgium: ESANN 2022 Proceedings: European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning, 2022.
- [10] I. Díaz, M. Domínguez, A. A. Cuadrado, A. B. Díez, and J. J. Fuertes, "MorphingProjections: Interactive Visualization of Electric Power Demand Time Series," 2012, doi: 10.2312/PE/EuroVisShort/EuroVisShort2012/121-125.
- [11] Y. Ma and H. Ghasemzadeh, "LabelForest: Non-Parametric Semi-Supervised Learning for Activity Recognition." [Online]. Available: <https://doi.org/10.1609/aaai.v33i01.33014520>

Semi-Supervised Learning

Pablo Laviana Martínez, 2025. Universidad de Oviedo

Morphing projections (PCA + UMAP + tSNE + Autoencoder latent space) + linked selections

lambda PCA: -5

lambda UMAP: -5

lambda tSNE: 5

lambda autoencoder: -5

Timestamps seleccionados:

3/7/2024, 11:35:55

3/7/2024, 11:36:24

3/7/2024, 11:36:53

3/7/2024, 11:37:23

3/7/2024, 11:37:52

... y 5027 más.

